

Πανεπιστήμιο Θεσσαλίας
Τμήμα Ψηφιακών Συστημάτων
Μηχανική Λογισμικού
για Διαδικτυακές & Φορητές Εφαρμογές
Εργασία Εαρινού εξαμήνου 2025 - 2026
Αποθήκες Δεδομένων



Θέμα:

**Σχεδιασμός και Ανάπτυξη Αποθήκης Δεδομένων για
την Παρακολούθηση της Ποιότητας του αέρα και των
μετεωρολογικών Συνθηκών στην Αθήνα (2020–2023)**

Χουλιάρας Δημήτριος
AM: M013125027
dimichou3@uth.gr

Ιούνιος 2026

Περιεχόμενα

1. Εύρεση και κατανόηση του χώρου εφαρμογής της Αποθήκης Δεδομένων	3
2. Εύρεση και κατανόηση των δεδομένων που θα αποθηκευτούν στην Αποθήκη Δεδομένων	3
3. Σχεδίαση της Αποθήκης Δεδομένων	4
Πίνακες Διαστάσεων (Dimensions).....	4
Πίνακας Γεγονότων (Fact Table).....	5
4. Διαδικασία ETL (extract, transform, load).....	6
4.1.Σύνδεση με την Πηγή και Αρχική Επεξεργασία (athens_data)	6
4.2 Δημιουργία Πίνακα Σταθμών (dim_station) και Γεωγραφική Κατηγοριοποίηση	7
4.3 Δημιουργία Πίνακα Χρόνου (dim_time)	8
4.4 Πίνακας Διάστασης Χαρακτηριστικών Εδάφους (dim_terrain_specs).....	9
4.5 Πίνακας Διάστασης Κατηγοριών Ποιότητας Αέρα (dim_aqi_categories).....	10
4.6 Πίνακας Διάστασης Μεταδεδομένων Ρύπων (dim_pollutant_metadata)	11
4.7 Πίνακας Γεγονότων (fact_air_quality) – Τελική Μορφή	12
5. Υλοποίηση της Αποθήκης Δεδομένων.....	13
5.1 Σενάριο Δημιουργίας Βάσης και Πινάκων (SQL DDL).....	13
5.2 Φόρτωση Δεδομένων (Data Loading)	13
5.3 Τεχνικές Προκλήσεις και Μετασχηματισμός Δεδομένων (Data Cleaning & Transformation).....	14
5.4 Έλεγχος Ορθότητας και Επαλήθευση (Verification).....	15
6. Διατύπωση SQL ερωτημάτων.....	16
7. Οπτικοποίηση και ανάλυση των SQL ερωτημάτων	18
8. Συμπεράσματα.....	24
8.1 Αξιολόγηση του Μοντέλου	24
8.2 Περιβαλλοντικά Ευρήματα	24
9. Βιβλιογραφία.....	25
Πρωτογενή Δεδομένα (Datasets):	25
Εργαλεία Λογισμικού:.....	25

1. Εύρεση και κατανόηση του χώρου εφαρμογής της Αποθήκης Δεδομένων

Ο χώρος εφαρμογής της παρούσας Αποθήκης Δεδομένων (ΑΔ) είναι η Περιβαλλοντική Μηχανική (Environmental Engineering) και η Δημόσια Υγεία. Η παρακολούθηση της ατμοσφαιρικής ρύπανσης αποτελεί κρίσιμη προτεραιότητα για τις σύγχρονες μεγαλουπόλεις, όπως η Αθήνα, καθώς τα επίπεδα των ρύπων επηρεάζουν άμεσα την ποιότητα ζωής των πολιτών και τις αποφάσεις των δημόσιων φορέων.

2. Εύρεση και κατανόηση των δεδομένων που θα αποθηκευτούν στην Αποθήκη Δεδομένων

Τα δεδομένα που θα εισαχθούν στην ΑΔ προέρχονται από το **Copernicus Atmosphere Monitoring Service (CAMS)** και ανακτήθηκαν μέσω των πλατφορμών Zenodo και Kaggle.

Χαρακτηριστικά Dataset:

- Γεωγραφική Κάλυψη: Σταθμοί μέτρησης εντός του λεκανοπεδίου Αττικής.
- Χρονική Ανάλυση: Ωριαίες καταγραφές (hourly resolution) για το διάστημα Μάιος 2020 έως και Μάιος 2023.
- Όγκος Δεδομένων: 1.726.464 εγγραφές.

Κατηγορίες Μεταβλητών:

1. Ρύποι (Pollutants): Διοξείδιο του αζώτου (NO₂), Όζον (O₃), Αιωρούμενα σωματίδια (PM₁₀, PM_{2.5}).
2. Μετεωρολογικά Στοιχεία: Θερμοκρασία αέρα, Μέση Θερμοκρασία Εδάφους, Σχετική υγρασία, Ταχύτητα και διεύθυνση ανέμου, Ύψος βροχόπτωσης.
3. Περιβαλλοντικά Στοιχεία: Επίπεδα βλάστησης (High/Low Vegetation) και θερμοκρασία εδάφους ανά σταθμό.
4. Κατά τη διαδικασία επεξεργασίας, οι γεωγραφικές συντεταγμένες (Latitude/Longitude) των σταθμών θα κατηγοριοποιηθούν σε Γεωγραφικούς Τομείς της Αθήνας (π.χ. Βόρεια, Νότια, Ανατολικά, Δυτικά, Κέντρο) και θα προκύψει ο Geographic_Sector προκύπτει από τον χωρισμό της Αθήνας σε 9 τομείς (λογική "τρίλιζας")

3. Σχεδίαση της Αποθήκης Δεδομένων

Για την υλοποίηση της Αποθήκης Δεδομένων επιλέχθηκε η αρχιτεκτονική Star Schema (Σχήμα Αστέρα), η οποία προσφέρει υψηλή ταχύτητα στα ερωτήματα (queries), απλότητα στην κατανόηση, ακεραιότητα των δεδομένων και βελτιστοποιεί τα ερωτήματα SQL. Το μοντέλο αποτελείται από έναν κεντρικό Πίνακα Γεγονότων (fact_air_quality) που συνδέεται με τρεις Πίνακες Διαστάσεων (dim_station, dim_time, dim_terrain_specs) μέσω σχέσεων 1:N (One-to-Many).

Οι πίνακες dim_aqi_categories και dim_pollutant_metadata λειτουργούν ως πίνακες αναφοράς. Αν και δεν συνδέονται με άμεση σχέση ξένου κλειδιού στον Πίνακα Γεγονότων, χρησιμοποιούνται για το δυναμικό φιλτράρισμα και την ποιοτική κατηγοριοποίηση των μετρήσεων κατά τη φάση της οπτικοποίησης και της εκτέλεσης SQL ερωτημάτων.

Πίνακες Διαστάσεων (Dimensions)


- dim_station: Περιλαμβάνει τις πληροφορίες των σταθμών μέτρησης της Αθήνας
Πεδία: station_key (PK),
source_station_id,
station_name,
latitude,
longitude,
geographic_sector
- dim_time: Επιτρέπει τη χρονική ανάλυση των δεδομένων
Πεδία: time_key (PK),
full_date,
hour (0-23),
day_of_Week,
month,
year,
is_weekend
- dim_terrain_specs: Περιγράφει τις συνθήκες γύρω από τον σταθμό
Πεδία: terrain_Key (PK),
vegetation_high,
vegetation_low,
vegetation_index

- **dim_aqi_categories:** Πίνακας αναφοράς για την ποιότητα του αέρα (Ε.Ε.)
Πεδία: aqi_category_key (PK),
pollutant_name (PM10, NO2, κ.λπ)
category_name (Καλή, Μέτρια, κ.λπ.),
lower_limit,
upper_limit,
health_advice,
color_code
- **dim_pollutant_metadata:** Πίνακας αποθετηρίου μεταδεδομένων για την
επεξήγηση των μετρήσεων και των ορίων ασφαλείας των ρύπων
Πεδία: pollutant_Key (PK),
pollutant_Name (π.χ. NO2),
full_Name (π.χ. Διοξείδιο του Αζώτου),
unit ($\mu\text{g}/\text{m}^3$),
eu_safe_limit,
limit_type (Daily για PM10, Hourly για NO2)
health_impact_description

Πίνακας Γεγονότων (Fact Table)

- **fact_air_quality:** Ο κεντρικός πίνακας που καταγράφει τις μετρήσεις και τα
ξένα κλειδιά προς τις διαστάσεις.
Πεδία: station_key (FK, PK),
time_key (FK, PK),
terrain_key (FK, PK),
no2, // διοξειδίου του αζώτου
o3, // όζον
pm10, // ατμοσφαιρικά αερολύματα με μέγιστη διάμετρο 10 μm
pm2.5, // ατμοσφαιρικά αερολύματα με μέγιστη διάμετρο 2.5 μm
temp, // ατμοσφαιρική θερμοκρασία
relative_humidity, // ποσότητα υδρατμών στον αέρα (%)
total_precipitation, // βροχή που φτάνει στην επιφάνεια της γης
soil_temp // μέση θερμοκρασία εδάφους
dewpoint_temp, // σημείο θερμοκρασίας στο οποίο ο αέρας δεν
μπορεί να συγκρατήσει άλλο νερό (υδρατμούς)
wind_speed_u, // Η συνιστώσα του ανέμου U είναι παράλληλη με
τον άξονα x (δηλαδή, γεωγραφικό μήκος).
Θετικό U προέρχεται από τη δύση και ένα
αρνητικό U προέρχεται από την ανατολή (m/s).
wind_speed_v, // Η συνιστώσα του ανέμου V είναι παράλληλη με
τον άξονα y (δηλαδή, γεωγραφικό πλάτος).
Θετικό V προέρχεται από το νότο και ένα
αρνητικό V προέρχεται από το βορρά (m/s).

Στο περιβάλλον *Visual Paradigm* υλοποιήθηκε το παρακάτω Σχήμα Αστέρα που αποτυπώνει τον κεντρικό Πίνακα Γεγονότων να συνδέεται με τους τρεις Πίνακες Διαστάσεων μέσω σχέσεων 1:N (One-to-Many) μαζί με έναν ακόμη 4^ο και 5^ο Πίνακα Διαστάσεων οι οποίοι λειτουργούν ως πίνακες αναφοράς (*metadata*).



4. Διαδικασία ETL (extract, transform, load)

Η διαδικασία ETL είναι πολύ σημαντική και παίζει καθοριστικό ρόλο για την υλοποίηση της Αποθήκης Δεδομένων. Για την εκτέλεσή της επιλέχθηκε το περιβάλλον του **Microsoft Power BI** και συγκεκριμένα ο επεξεργαστής **Power Query** κυρίως γιατί προσφέρει ευελιξία, ταχύτητα, επαναληψιμότητα και ενοποίηση για τη συνεχή επαλήθευση των δεδομένων κατά τη διάρκεια της ανάπτυξης

4.1. Σύνδεση με την Πηγή και Αρχική Επεξεργασία (*athens_data*)

Το πρώτο στάδιο του ETL ήταν η εισαγωγή του αρχείου *athens_data.csv*. Στο κεντρικό αυτό query πραγματοποιήθηκαν οι απαραίτητες ενέργειες ώστε τα δεδομένα να είναι έτοιμα προς διαχωρισμό:

- Εισαγωγή Δεδομένων (Source): Σύνδεση με το αρχείο CSV και αυτόματη αναγνώριση της κωδικοποίησης.
- Προαγωγή Κεφαλίδων (Promoted Headers): Η πρώτη γραμμή του αρχείου μετατράπηκε σε ονόματα στηλών, ώστε τα πεδία (π.χ. *Station_ID*, *Pollutant*) να είναι αναγνωρίσιμα.
- Αρχική Αλλαγή Τύπων (Changed Type): Το Power BI απέδωσε αυτόματα τύπους δεδομένων, οι οποίοι ελέγχθηκαν και διορθώθηκαν όπου χρειαζόταν (π.χ. ημερομηνίες, ακέραιοι).


Το query *athens_data* παρέμεινε ως η πηγή αλήθειας. Για τη δημιουργία των Πινάκων Διαστάσεων (*dim_station*, *dim_time*, *dim_terrain_specs*), χρησιμοποιήθηκε η μέθοδος της Αναφοράς (Reference). Με αυτόν τον τρόπο, αν αλλάξει κάτι στο αρχικό αρχείο, οι αλλαγές θα μεταφερθούν αυτόματα σε όλους τους πίνακες.

4.2 Δημιουργία Πίνακα Σταθμών (dim_station) και Γεωγραφική Κατηγοριοποίηση

Για την υλοποίηση του πίνακα των σταθμών, δημιουργήθηκε μια **Αναφορά** από το αρχικό query athens_data. Η διαδικασία αυτή διασφαλίζει ότι οποιαδήποτε μελλοντική αλλαγή στην πηγή θα ενημερώνει αυτόματα τη διάσταση των σταθμών.

Τα βήματα που ακολουθήθηκαν αναλυτικά:

- Επιλογή Στηλών: Διατηρήθηκαν μόνο τα πεδία που περιγράφουν την οντότητα του σταθμού: Station_ID, Station_Name, Latitude και Longitude.
- Αφαίρεση Διπλοτύπων: Επειδή το αρχικό αρχείο περιέχει εκατομμύρια εγγραφές (μία για κάθε ώρα μέτρησης), εφαρμόστηκε η εντολή Remove Duplicates στη στήλη Station_ID. Αποτέλεσμα ήταν ο πίνακας να περιοριστεί στους 64 μοναδικούς σταθμούς της Αθήνας.
- Διόρθωση Δεκαδικών: Λόγω της χρήσης τελείας ως διαχωριστικό δεκαδικών στο αρχείο CSV, χρησιμοποιήθηκε η λειτουργία **Change Type with Locale** με ρύθμιση English (United States) για τις στήλες Latitude και Longitude. Αυτό απέτρεψε το σφάλμα λανθασμένης ανάγνωσης των συντεταγμένων (π.χ. το 38.15 να διαβαστεί ως 3815).
- Δημιουργία Πρωτεύοντος Κλειδιού (station key): Προστέθηκε μια στήλη δείκτη ξεκινώντας από το 1. Αυτό είναι απαραίτητο για τη βέλτιστη απόδοση της Αποθήκης Δεδομένων και τη σύνδεση με τον Πίνακα Γεγονότων.
- Γεωγραφική Κατηγοριοποίηση (Spatial Binning): Με στόχο την ευκολότερη ανάλυση των ρύπων ανά περιοχή, δημιουργήθηκε η προσαρμοσμένη στήλη geographic_sector. Χρησιμοποιήθηκε γλώσσα προγραμματισμού **M** με σύνθετη λογική if...then...else, η οποία χωρίζει την Αττική σε 9 τομείς (North-West, Central, South-East κ.λπ.) βάσει των ορίων Latitude και Longitude.



Οπτική Επαλήθευση

Η ορθότητα των παραπάνω μετασχηματισμών ελέγχθηκε μέσω της απεικόνισης **Map** στο **Power BI**. Κάθε σταθμός τοποθετήθηκε στον χάρτη βάσει των συντεταγμένων του και χρωματίστηκε βάσει του τομέα του.

4.3 Δημιουργία Πίνακα Χρόνου (dim_time)

Η διάσταση του χρόνου σχεδιάστηκε με σκοπό την ανάλυση των ρύπων σε πολλαπλά επίπεδα χρονικής ιεραρχίας. Η υλοποίηση έγινε μέσω Reference στο αρχικό Query και περιλαμβάνει τα εξής στάδια:

- **Διασφάλιση Μοναδικότητας:** Εφαρμόστηκε αφαίρεση διπλοτύπων στη στήλη της ημερομηνίας, ώστε κάθε χρονική στιγμή (hour-by-hour) να αποτελεί μια μοναδική εγγραφή στον πίνακα. Από το αρχικό 1.500.000 εγγραφών, ο πίνακας περιορίστηκε σε περίπου 26.976 μοναδικές χρονικές στιγμές.
- **Χρονική Ανάλυση:** Από την αρχική στήλη full_date, εξήχθησαν αυτόνομες στήλες για την Ώρα (hour), τον Μήνα (month) και το Έτος (year). Αυτό μας επιτρέπει να φιλτράρουμε τα δεδομένα ανά εποχή ή ανά ώρα αιχμής.
- **Ανάλυση Ημερών:** Δημιουργήθηκε η στήλη day_of_week με τα ονόματα των ημερών.
- **Υπολογιζόμενο Πεδίο Σαββατοκύριακου:** Με τη χρήση γλώσσας M, δημιουργήθηκε η στήλη is_weekend. Χρησιμοποιήθηκε η συνάρτηση Date.DayOfWeek, ώστε να κατηγοριοποιηθούν αυτόματα οι ημέρες σε "Yes" (για Σάββατο και Κυριακή) και "No" (για τις καθημερινές).
- **Surrogate Key:** Προστέθηκε το time_key ως Πρωτεύον Κλειδί για τη σύνδεση με τον πίνακα γεγονότων.

The screenshot shows the Power BI Desktop interface with the following components:

- Top Ribbon:** Includes tabs for 'Αρχείο', 'Κεντρική', 'Μετασχηματισμός', 'Προσθήκη στήλης', 'Προβολή', 'Εργαλεία', and 'Βοήθεια'.
- Formula Bar:** Displays the DAX expression: `= Table.AddColumn(#"Κατάργηση στήλων", "is_weekend", each if Date.DayOfWeek([full_date], Day.Monday) >= 5 then "Yes" else "No")`.
- Table View:** Shows a table with columns: full_date, hour, month, year, dayofweek, and is_weekend. The data represents hourly records for January 5, 2020, showing a Saturday.
- Right Sidebar (Model View):** Lists the tables in the data model: 'athens_data', 'dim_station', and 'dim_time'. The 'dim_time' table is selected.
- Bottom Section (Data View):** Displays a bar chart visualization of the data, with the x-axis representing time and the y-axis representing a value.

4.4 Πίνακας Διάστασης Χαρακτηριστικών Εδάφους (dim_terrain_specs)


Ο πίνακας dim_terrain_specs δημιουργήθηκε για να ομαδοποιήσει τις χιλιάδες μεμονωμένες μετρήσεις των δεικτών βλάστησης (vegetation_high και vegetation_low) σε διακριτές, ερμηνεύσιμες κατηγορίες. Στόχος είναι να μελετηθεί πώς το περιβάλλον γύρω από κάθε σταθμό επηρεάζει τη συγκέντρωση των ρύπων. Λόγω της φύσης των δορυφορικών δεδομένων, εφαρμόστηκαν τα εξής βήματα:

- **Διαχείριση Κενών Τιμών (Nulls):** Οι κενές τιμές αντικαταστάθηκαν με την τιμή 0, ώστε να καταλογιστούν στην κατηγορία έλλειψης δεδομένων.
- **Στρογγυλοποίηση:** Οι τιμές στρογγυλοποιήθηκαν στο **1 δεκαδικό ψηφίο**. Αυτή η στρατηγική επέτρεψε τη δραματική μείωση του όγκου των δεδομένων από **1.726.464 εγγραφές** σε μόλις **78 μοναδικά προφίλ εδάφους** και αποτέλεσε κρίσιμο βήμα για την βελτιστοποίηση του μοντέλου καθώς μετέτρεψε μια συνεχή μεταβλητή σε διακριτές κατηγορίες.
- **Κατάργηση Διπλοτύπων:** Μετά τη στρογγυλοποίηση, αφαιρέθηκαν όλες οι επαναλαμβανόμενες γραμμές, δημιουργώντας έναν αποδοτικό πίνακα.

Επειδή οι αριθμητικές τιμές του dataset είναι από 0 έως 2.3 (κλίμακα δείκτη), δημιουργήθηκε μια συνδυαστική λογική (if-then-else logic) για την κατάταξη των σταθμών σε 4 επίπεδα. Η ονοματολογία "Index" προτιμήθηκε αντί για απόλυτους όρους (π.χ. Δάσος), ώστε να διασφαλιστεί η επιστημονική εγκυρότητα.

Κατηγοριοποίηση για τα δεδομένα:

Level	vegetation_high	vegetation_low	vegetation_index
Level 4	≥ 1.8	οποιοδήποτε	Very High Vegetation Index
Level 3	1.3 έως 1.8	> 1.5	High Vegetation Index
Level 2	0.8 έως 1.3	≤ 1.5	Moderate Vegetation Index
Level 2	< 0.8	> 1.4	Moderate Vegetation Index
Level 1	< 0.5	< 1.0	Low / Urban Index
-	0	0	No Data / Null



4.5 Πίνακας Διάστασης Κατηγοριών Ποιότητας Αέρα (dim_aqi_categories)

Ο πίνακας dim_aqi_categories δημιουργήθηκε ως πίνακας αναφοράς για να δώσει ποιοτικό περιεχόμενο στις αριθμητικές μετρήσεις των ρύπων. Χωρίς αυτόν τον πίνακα, οι τιμές συγκέντρωσης (π.χ. 45μg/m³ NO₂) θα παρέμεναν απλά νούμερα χωρίς πλαίσιο επικινδυνότητας για τον τελικό χρήστη.

Για τον καθορισμό των ορίων χρησιμοποιήθηκαν τα επίσημα πρότυπα του **Ευρωπαϊκού Οργανισμού Περιβάλλοντος (ΕΕΑ)** τα οποία αφορούν ωριαίες μετρήσεις όπως και η χρονική ανάλυση των δεδομένων της Αθήνας

- Εισαγωγή Δεδομένων: Ο πίνακας δημιουργήθηκε με τη χρήση της λειτουργίας **Enter Data** στο Power BI.
- Προσαρμογή Ορίων: Οι κλίμακες μετατράπηκαν σε διακριτά πεδία lower_limit και upper_limit για να είναι δυνατή η μετέπειτα σύνδεση με τον Fact πίνακα.

Pollutant	Index level (based on pollutant concentrations in µg/m3)					
	Good	Fair	Moderate	Poor	Very poor	Extremely poor
Particles less than 2.5 µm (PM _{2.5})	0-5	6-15	16-50	51-90	91-140	>140
Particles less than 10 µm (PM ₁₀)	0-15	16-45	46-120	121-195	196-270	>270
Ozone (O ₃)	0-60	61-100	101-120	121-160	161-180	>180
Nitrogen dioxide (NO ₂)	0-10	11-25	26-60	61-100	101-150	>150
Sulphur dioxide (SO ₂)	0-20	21-40	41-125	126-190	191-275	>275

The screenshot displays the Microsoft Power BI Desktop environment. The main window shows a data table with columns: `aqi_category_key`, `pollutant_name`, `category_name`, `lower_limit`, `upper_limit`, and `health_advice`. The table contains 20 rows of data for various pollutants like NO₂, O₃, PM₁₀, and PM_{2.5}, categorized into Good, Fair, Moderate, Poor, Very poor, and Extremely poor. On the left, the 'Ερωτήματα (5)' pane lists the data sources: `athens_data`, `dim_station`, `dim_time`, `dim_terrain_specs`, and `dim_aqi_categories`. On the right, the 'Ρυθμίσεις ερωτήματος' pane shows the 'dim_aqi_categories' table selected. At the bottom, a 'Στατιστικά στοιχεία στήλης' pane shows the distribution of the `category_name` field, with a bar chart indicating the frequency of each category (Good, Fair, Moderate, Poor, Very poor, Extremely poor).

4.6 Πίνακας Διάστασης Μεταδεδομένων Ρύπων (dim_pollutant_metadata)

Ο πίνακας dim_pollutant_metadata λειτουργεί ως ο κεντρικός κατάλογος αναφοράς για τους ρύπους 4 διαφορετικούς ρύπους που εξετάζονται στην παρούσα μελέτη (NO2, O3, PM10, PM2.5).

Στην προκειμένη περίπτωση δεν εφαρμόστηκαν κάποια βήματα για την επεξεργασία των δεδομένων, παρά μόνο η σωστή διαχείριση τους για το διάβασμα των ελληνικών γραμμάτων και των κατάλληλων συμβόλων

- **Περιεχόμενο:** Περιλαμβάνει τις πλήρεις ονομασίες, τις μονάδες μέτρησης και τα επίσημα ετήσια όρια ασφαλείας όπως αυτά ορίζονται από την Ευρωπαϊκή νομοθεσία (EU Air Quality Standards).
- **Λειτουργικότητα:** Η προσθήκη στηλών όπως οι limit_description και health_impact_description επιτρέπει την παραγωγή αναφορών που δεν είναι μόνο στατιστικές, αλλά και ενημερωτικές, συνδέοντας τα επίπεδα ρύπανσης με τις άμεσες επιπτώσεις στη δημόσια υγεία.
- **Σύνδεση:** Ο πίνακας συνδέεται με το Fact Table μέσω της στήλης pollutant_name, επιτρέποντας το δυναμικό φιλτράρισμα των δεδομένων σε ολόκληρο το μοντέλο.

“Σημειώνεται ότι τα θεσμοθετημένα όρια (EU Safe Limits) αφορούν τη μέση ετήσια συγκέντρωση και λειτουργούν συμπληρωματικά προς τις ωριαίες κατηγορίες AQI, επιτρέποντας τη διπλή αξιολόγηση των δεδομένων: τόσο σε επίπεδο άμεσης επικινδυνότητας όσο και σε επίπεδο μακροχρόνιας επιβάρυνσης.”

The screenshot displays the Power BI Desktop interface. The main view shows a table named 'Table.TransformColumnTypes' with the following data:

pollutant_key	pollutant_name	full_name	unit	eu_safe_limit	limit_description	health_impact
1	NO2	Nitrogen Dioxide	µg/m³	40	Annual mean limit (EU)	Respiratory infla
2	O3	Ozone	µg/m³	120	8-hour mean limit (EU)	Irritation of eyes
3	PM10	Particular Matter < 10µm	µg/m³	40	Annual mean limit (EU)	Affects heart and
4	PM2.5	Particular Matter < 2.5µm	µg/m³	25	Annual mean limit (EU)	Severe respirato

The interface also shows the 'Columns' pane on the left with a list of dimensions: athens_data, dim_station, dim_time, dim_terrain_specs, dim_aqi_categories, dim_pollutant_metadata, and fact_air_quality. The 'Fields' pane on the right shows a list of measures: Προέλευση, Αλλαγή τύπου, and Αλλαγή τύπου.

4.7 Πίνακας Γεγονότων (fact_air_quality) – Τελική Μορφή

Μετά την ολοκλήρωση των πινάκων διαστάσεων, ο πίνακας γεγονότων fact_air_quality υπέστη την τελική του επεξεργασία μέσω της διαδικασίας Merge Queries στον Power Query Editor. Στόχος ήταν η αντικατάσταση των περιγραφικών στηλών με τα αντίστοιχα κλειδιά για τη δημιουργία ενός αποδοτικού Star Schema.

1. Σύνδεση και Συσχετίσεις (Key Mapping)

Για κάθε εγγραφή μέτρησης, έγινε η αντιστοίχιση με τους πίνακες διαστάσεων:

- station_key: Αντικατέστησε το όνομα/ID του σταθμού, συνδέοντας κάθε μέτρηση με τον πίνακα dim_station.
- time_key: Αντικατέστησε την ημερομηνία και την ώρα, συνδέοντας τη μέτρηση με το χρονικό πλαίσιο του dim_time.
- terrain_key: Αντικατέστησε τις τιμές βλάστησης (vegetation_high/low), συνδέοντας τα δεδομένα με τα χαρακτηριστικά εδάφους του dim_terrain_specs.


2. Περιεχόμενο και Μετρήσιμα Μεγέθη (Metrics)

Ο πίνακας διατήρησε όλες τις ποσοτικές μεταβλητές για την ανάλυση:

- Ρύποι: Συγκεντρώσεις NO2, O3, PM10 και PM2.5 (σε $\mu\text{g}/\text{m}^3$)
- Μετεωρολογικά Δεδομένα: Θερμοκρασία (Temp), Σχετική Υγρασία (Relative Humidity), Βροχόπτωση (Total Precipitation), Σημείο Δρόσου (Dewpoint Temp) και συνιστώσες ανέμου (Wind Speed U/V).

3. Βελτιστοποίηση

Μετά την εισαγωγή των κλειδιών, όλες οι πλεονάζουσες στήλες κειμένου αφαιρέθηκαν. Αυτό είχε ως αποτέλεσμα έναν πίνακα που αποτελείται αποκλειστικά από **αριθμητικά δεδομένα**, γεγονός που ελαχιστοποιεί το μέγεθος της βάσης δεδομένων και μεγιστοποιεί την ταχύτητα εκτέλεσης των ερωτημάτων SQL.



5. Υλοποίηση της Αποθήκης Δεδομένων

Η υλοποίηση της Αποθήκης Δεδομένων πραγματοποιήθηκε στο Σύστημα Διαχείρισης Σχεσιακών Βάσεων Δεδομένων (RDBMS) **MySQL 8.0**, χρησιμοποιώντας το πακέτο **XAMPP** για τη φιλοξενία του Local Server. Η μετάβαση από το περιβάλλον ανάλυσης του **Power BI** στην βάση δεδομένων της **MySQL** οργανώθηκε ως μια ολοκληρωμένη διαδικασία **ETL (Extract, Transform, Load)**.

Κεντρικό ρόλο σε αυτή τη διαδικασία έπαιξε το εργαλείο **DAX Studio**, το οποίο χρησιμοποιήθηκε για την εξαγωγή των δεδομένων από το In-Memory μοντέλο του Power BI. Λόγω του μεγάλου όγκου των δεδομένων (άνω των 1,7 εκατομμυρίων εγγγραφών), το DAX Studio διασφάλισε ότι η πληροφορία μεταφέρθηκε αυτούσια και χωρίς απώλειες σε αρχεία μορφής CSV.

5.1 Σενάριο Δημιουργίας Βάσης και Πινάκων (SQL DDL)

Για τη δημιουργία του σχήματος χρησιμοποιήθηκε γλώσσα DDL (Data Definition Language). Ο κώδικας ορίζει τη δομή των πινάκων, τους τύπους δεδομένων, καθώς και τους περιορισμούς ακεραιότητας (Primary Keys και Foreign Keys).

- **Surrogate Keys:** Όλοι οι πίνακες διαστάσεων διαθέτουν τεχνητά κλειδιά (Integer) για βέλτιστη απόδοση στις ενώσεις (joins).
- **Data Integrity:** Ο πίνακας γεγονότων (fact_air_quality) συνδέεται με τους πίνακες σταθμών, χρόνου και εδάφους μέσω Foreign Keys.

5.2 Φόρτωση Δεδομένων (Data Loading)

- **Στρατηγική Εξαγωγής (Extraction):** Η εξαγωγή των πινάκων πραγματοποιήθηκε μέσω της λειτουργίας Export Data του DAX Studio. Η επιλογή αυτή ήταν καθοριστική για τη διαχείριση του Fact Table, καθώς επέτρεψε την εξαγωγή 1,7 εκατομμυρίων γραμμών σε σταθερά αρχεία CSV.
- **Πλήθος Δεδομένων:** Στον κεντρικό πίνακα γεγονότων (fact_air_quality) φορτώθηκαν συνολικά **1.726.464 εγγραφές**, καλύπτοντας την περίοδο 2020-2023.
- **Μέθοδος Μεταφοράς:** Η εξαγωγή έγινε σε μορφή CSV. Για την εισαγωγή χρησιμοποιήθηκε η εντολή LOAD DATA INFILE, η οποία προτιμήθηκε έναντι του Wizard για λόγους ταχύτητας και για να επιτραπεί η παραμετροποίηση των δεδομένων κατά την εισαγωγή.

5.3 Τεχνικές Προκλήσεις και Μετασχηματισμός Δεδομένων (Data Cleaning & Transformation)

Κατά τη διαδικασία της φόρτωσης αντιμετωπίστηκαν σημαντικές προκλήσεις που απαιτούσαν προηγμένο SQL scripting:

- **Ασυμβατότητα Δεκαδικών (Decimal Formatting):** Τα αρχεία προέλευσης χρησιμοποιούσαν το κόμμα (,) ως δεκαδικό διαχωριστικό. Χρησιμοποιήθηκε η συνάρτηση REPLACE() εντός της εντολής φόρτωσης για τη δυναμική μετατροπή τους σε τελεία (.), ώστε να αναγνωρίζονται ως αριθμητικά πεδία (FLOAT/DECIMAL) από τη MySQL.

```
-- Παράδειγμα στην SQL για τη στήλη θερμοκρασίας του πίνακα  
fact_air_quality  
temp = REPLACE(@v_temp, ',', '.')
```

- **Διαχείριση Κενών Τιμών (Null Handling):** Σε πολλές μετρήσεις ρύπων υπήρχαν κενά πεδία (missing values). Για να αποφευχθούν σφάλματα τύπου "Incorrect numeric value", χρησιμοποιήθηκε η συνάρτηση NULLIF(), η οποία μετέτρεψε τα κενά κείμενα σε πραγματικά NULL στη βάση δεδομένων.

```
-- Παράδειγμα στην SQL για τη στήλη NO2 του πίνακα fact_air_quality  
no2 = NULLIF(REPLACE(@v_no2, ',', '.'), '')
```

- **Μορφοποίηση Ημερομηνιών:** Οι ημερομηνίες στον πίνακα dim_time περιείχαν κλάσματα δευτερολέπτου (milliseconds) σε μη συμβατή μορφή. Έγινε χρήση της STR_TO_DATE() για τον σωστό συγχρονισμό του χρονικού αποτυπώματος.

```
-- Παράδειγμα στην SQL για μετατροπή κειμένου σε DateTime format του  
πίνακα dim_time  
SET full_time = STR_TO_DATE(@v_time_string, '%Y-%m-%d %H:%i:%s');
```

- **Βελτιστοποίηση Απόδοσης (Performance Tuning):** Λόγω του μεγάλου όγκου δεδομένων (1,7M+ γραμμές), απενεργοποιήθηκαν προσωρινά οι έλεγχοι ξένων κλειδιών (FOREIGN_KEY_CHECKS=0) και το AUTOCOMMIT, ενώ αυξήθηκαν τα Timeouts του διακομιστή για να ολοκληρωθεί η εισαγωγή χωρίς διακοπή της σύνδεσης.

```
-- Παράδειγμα στην SQL του πίνακα dim_time  
  
// Απενεργοποίηση ελέγχων και αυτόματων εγγραφών  
SET FOREIGN_KEY_CHECKS = 0; SET AUTOCOMMIT = 0;  
  
{ *** [Εκτέλεση LOAD DATA INFILE] *** }  
  
// Οριστικοποίηση και επαναφορά ελέγχων  
COMMIT; SET FOREIGN_KEY_CHECKS = 1;
```


5.4 Έλεγχος Ορθότητας και Επαλήθευση (Verification)

Μετά την ολοκλήρωση της φόρτωσης, πραγματοποιήθηκαν οι εξής έλεγχοι για τη διασφάλιση της ακεραιότητας:

- **Row Count Validation:** Επιβεβαιώθηκε ότι το πλήθος των εγγραφών στη MySQL (1.726.464) ταυτίζεται απόλυτα με το dataset του Power BI.

```
1 • SELECT FORMAT(COUNT(*), 0) AS 'Total Rows (Fact Table)'
2 FROM fact_air_quality;
```

Total Rows (Fact Table)
1,726,464

- **Data Quality Check:** Πραγματοποιήθηκαν queries ελέγχου για την εύρεση μηδενικών ή λανθασμένων τιμών. Διαπιστώθηκε ότι οι ρύποι NO2 και O3 διαθέτουν έγκυρες μετρήσεις για το 91.70% και 91.42% των εγγραφών αντίστοιχα, επιβεβαιώνοντας την επιτυχία του μετασχηματισμού.

```
1 • SELECT
2     FORMAT(COUNT(no2), 0) AS 'Rows with NO2',
3     ROUND((COUNT(no2) / COUNT(*)) * 100, 2) AS 'NO2 Success Rate %',
4     FORMAT(COUNT(o3), 0) AS 'Rows with O3',
5     ROUND((COUNT(o3) / COUNT(*)) * 100, 2) AS 'O3 Success Rate %'
6 FROM fact_air_quality;
```

Rows with NO2	NO2 Success Rate %	Rows with O3	O3 Success Rate %
1,583,171	91.70	1,578,400	91.42

- **Relational Integrity:** Εκτελέστηκαν δοκιμαστικά JOINS μεταξύ του Fact Table και των Dimension Tables (π.χ. συσχέτιση μετρήσεων με ονόματα σταθμών) για την επαλήθευση της ορθής λειτουργίας του Star Schema.

```
1 • SELECT
2     s.station_name AS 'Station Name',
3     ROUND(AVG(f.temp), 2) AS 'Avg Temp (°C)',
4     ROUND(AVG(f.pm10), 2) AS 'Avg PM10 (µg/m³)',
5     FORMAT(COUNT(*), 0) AS 'Total Measurements'
6 FROM fact_air_quality f
7 JOIN dim_station s ON f.station_key = s.station_key
8 GROUP BY s.station_name
9 ORDER BY AVG(f.pm10) DESC
10 LIMIT 10;
```

Station Name	Avg Temp (°C)	Avg PM10 (µg/m³)	Total Measurements
ATH-ENVICARE-3	17.87	32.87	26,976
ARISTOTELOUS	17.61	32.34	26,976
PERISTERI	17.66	30.25	26,976
PANACEA_049	17.36	28.99	26,976
PANACEA_019	17.42	28.97	26,976
ATH-ENVICARE-0	17.57	28.29	26,976
ATHINAS	14.40	28.29	26,976
PANACEA_048	17.30	28.09	26,976
SMYRNI	17.34	27.80	26,976
PPCITY21	17.59	27.45	26,976

6. Διατύπωση SQL ερωτημάτων

Αρχικά, πριν ξεκινήσουμε να τρέχουμε τα queries, για την καλύτερη και γρηγορότερη διέλευση των εγγραφών στον πίνακα fact_air_quality δημιουργήσαμε τα εξής indexes:

```
CREATE INDEX idx_station ON fact_air_quality(station_key);  
CREATE INDEX idx_time ON fact_air_quality(time_key);  
CREATE INDEX idx_terrain ON fact_air_quality(terrain_key);
```

Επειδή ο fact_air_quality έχει πάρα πολλές εγγραφές, η MySQL προσπαθεί να συγκρίνει εκατομμύρια συνδυασμούς. Με τα Indexes, αυτή η διαδικασία από "δευτερόλεπτα ή λεπτά" πέφτει σε χιλιοστά του δευτερολέπτου.

6.1 Υπολογισμός μέσης τιμής ρύπων PM10 για τους 10 πιο επιβαρυσμένους σταθμούς.

```
SELECT s.station_name, ROUND(AVG(f.pm10), 2) AS average_pm10  
FROM fact_air_quality f  
JOIN dim_station s ON f.station_key = s.station_key  
GROUP BY s.station_name  
ORDER BY average_pm10 DESC  
LIMIT 10;
```

6.2 Καταμέτρηση υπερβάσεων του ορίου ασφαλείας PM10 ανά γεωγραφικό τομέα.

```
SELECT s.geographic_sector, COUNT(*) AS exceedances_count  
FROM fact_air_quality f  
JOIN dim_station s ON f.station_key = s.station_key  
JOIN dim_pollutant_metadata m ON m.pollutant_name = 'PM10'  
WHERE f.pm10 > m.eu_safe_limit  
GROUP BY s.geographic_sector  
ORDER BY exceedances_count DESC;
```

6.3 Μέση μηνιαία διακύμανση NO2 και Θερμοκρασίας (Διαχρονικά)

```
SELECT t.month, ROUND(AVG(f.temp), 2) AS avg_temp, ROUND(AVG(f.no2),  
2) AS avg_no2  
FROM fact_air_quality f  
JOIN dim_time t ON f.time_key = t.time_key  
GROUP BY t.month  
ORDER BY t.month;
```

6.4 Μέση μηνιαία διακύμανση O3 και Θερμοκρασίας (Διαχρονικά)

```
SELECT t.month, ROUND(AVG(f.temp), 2) AS avg_temp, ROUND(AVG(f.o3), 2)
AS avg_o3
FROM fact_air_quality f
JOIN dim_time t ON f.time_key = t.time_key
GROUP BY t.month
ORDER BY t.month;
```

6.5 Εντοπισμός ωρών αιχμής της ρύπανσης (NO2) κατά τη διάρκεια της ημέρας.

```
SELECT t.hour AS 'Hour_of_Day', ROUND(AVG(f.no2), 2) AS 'Average_NO2',
CASE
    WHEN t.hour BETWEEN 5 AND 8 THEN 'Πρωινή Αιχμή'
    WHEN t.hour BETWEEN 19 AND 22 THEN 'Απογευματινή Αιχμή'
    ELSE 'Εκτός Αιχμής'
END AS 'Traffic_Period'
FROM fact_air_quality f
JOIN dim_time t ON f.time_key = t.time_key
GROUP BY t.hour, Traffic_Period
ORDER BY t.hour;
```

6.6 Μέση τιμή ρύπων κατά τις εργάσιμες ημέρες έναντι Σαββατοκύριακου.

```
SELECT
    CASE WHEN t.is_weekend = 'Yes' THEN 'Σαββατοκύριακο' ELSE
    'Καθημερινή' END AS day_type,
    ROUND(AVG(f.pm2_5), 2) AS avg_pm2_5,
    ROUND(AVG(f.pm10), 2) AS avg_pm10,
    ROUND(AVG(f.o3), 2) AS avg_o3,
    ROUND(AVG(f.no2), 2) AS avg_no2
FROM fact_air_quality f
JOIN dim_time t ON f.time_key = t.time_key
GROUP BY day_type;
```

6.7 Ποσοστιαία κατανομή ποιότητας αέρα (NO2) βάσει ευρωπαϊκών προτύπων για το έτος 2022 (ανά εγγραφή)

```
SELECT c.category_name AS air_quality_level, COUNT(*) AS
total_measurements FROM fact_air_quality f
JOIN dim_aqi_categories c ON c.pollutant_name = 'NO2'
JOIN dim_time t ON f.time_key = t.time_key
WHERE t.year = 2022 AND f.no2 >= c.lower_limit AND f.no2 <= c.upper_limit
GROUP BY c.category_name, c.aqi_category_key
ORDER BY c.aqi_category_key;
```

6.8 Ποσοστιαία κατανομή ποιότητας αέρα (NO2) βάσει ευρωπαϊκών προτύπων για το έτος 2022 (ανά ημέρα)

```
SELECT c.category_name AS daily_air_quality, COUNT(*) AS total_days
FROM (
    SELECT t.full_date, AVG(f.no2) AS avg_daily_no2
    FROM fact_air_quality f
    JOIN dim_time t ON f.time_key = t.time_key
    WHERE t.year = 2022
    GROUP BY t.full_date
) AS daily_stats
JOIN dim_aqi_categories c ON c.pollutant_name = 'NO2'
WHERE daily_stats.avg_daily_no2 >= c.lower_limit AND
daily_stats.avg_daily_no2 <= c.upper_limit
GROUP BY c.category_name, c.aqi_category_key
ORDER BY c.aqi_category_key;
```

6.9 Ταξινόμηση μέσων τιμών NO2 ανά σταθμό και κατηγορία ποιότητας.

```
SELECT s.station_name, ROUND(AVG(f.no2), 2) AS total_avg_no2,
IFNULL(c.category_name, 'No Data') AS overall_air_quality_status,
IFNULL(c.health_advice, 'Insufficient measurements for this period') AS
health_advice
FROM dim_station s
LEFT JOIN fact_air_quality f ON s.station_key = f.station_key
LEFT JOIN dim_aqi_categories c ON c.pollutant_name = 'NO2'
AND (
    SELECT ROUND(AVG(f2.no2), 2)
    FROM fact_air_quality f2
    WHERE f2.station_key = s.station_key
) BETWEEN c.lower_limit AND c.upper_limit
GROUP BY s.station_name, c.category_name, c.health_advice
ORDER BY total_avg_no2 DESC;
```


7. Οπτικοποίηση και ανάλυση των SQL ερωτημάτων

Στο παρόν κεφάλαιο παρουσιάζονται τα αποτελέσματα των ερωτημάτων (queries) που εκτελέστηκαν στην Αποθήκη Δεδομένων. Η οπτικοποίηση των δεδομένων υλοποιήθηκε με την χρήση του excel αφού πρώτα έγινε η εξαγωγή των αποτελεσμάτων σε csv μορφή από το περιβάλλον του MySQL.

7.1 Υπολογισμός μέσης τιμής ρύπων PM10 για τους 10 πιο επιβαρυμένους σταθμούς.

	station_name	average_pm10
▶	ATH-ENVICARE-3	32.87
	ARISTOTELOUS	32.34
	PERISTERI	30.25
	PANACEA_049	28.99
	PANACEA_019	28.97
	ATHINAS	28.29
	ATH-ENVICARE-0	28.29
	PANACEA_048	28.09
	SMYRNI	27.80
	PPCITY21	27.45

1 - Αποτέλεσμα SQL ερωτήματος 6.1




Το συγκεκριμένο ερώτημα υπολογίζει τη μέση συγκέντρωση των αιωρούμενων σωματιδίων PM10 ανά σταθμό μέτρησης και παρουσιάζει τους 10 σταθμούς με τις υψηλότερες τιμές σε φθίνουσα σειρά.

7.2 Καταμέτρηση υπερβάσεων του ορίου ασφαλείας PM10 ανά γεωγραφικό τομέα.

	geographic_sector	exceedances_count
▶	Κεντρικά	84386
	Δυτικά	34025
	Ανατολικά	23325
	Βόρειο-Κεντρικά	10073
	Νότιο-Δυτικά	9477
	Νότιο-Κεντρικά	9196
	Νότιο-Ανατολικά	7010
	Βόρειο-Ανατολικά	4021
	Βόρειο-Δυτικά	2584

2 - Αποτέλεσμα SQL ερωτήματος 6.2




Ο Κεντρικός τομέας παρουσιάζει τον μέγιστο βαθμό επικινδυνότητας με πάνω από 84.000 καταγεγραμμένες υπερβάσεις, ενώ ακολουθούν τα Δυτικά προάστια και μετά τα Ανατολικά Προάστια. Αντίθετα, οι Βόρειοι τομείς (Βόρειο-Κεντρικά) εμφανίζουν πιο καθαρές τιμές ενώ τα οι Νότιοι τομείς (Νότιο-Κεντρικά) τις καθαρότερες τιμές. Τα ευρήματα αυτά υπογραμμίζουν την ανάγκη για στοχευμένες περιβαλλοντικές αλλαγές στις πιο επιβαρυμένες περιοχές του λεκανοπεδίου.

7.3 Μέση μηνιαία διακύμανση NO2 και Θερμοκρασίας (Διαχρονικά)

	month	avg_temp	avg_no2
▶	1	8.54	23.06
	2	8.69	25.68
	3	9.89	22.38
	4	14.49	21.00
	5	19.80	21.86
	6	24.30	18.88
	7	27.11	15.66
	8	27.18	17.13
	9	23.08	19.11
	10	17.90	20.11
	11	13.77	20.93
	12	10.85	21.80

3 - Αποτέλεσμα SQL ερωτήματος 6.3




Η ανάλυση της μέσης μηνιαίας διακύμανσης αποδεικνύει την άμεση εξάρτηση της ποιότητας του αέρα από τις εποχιακές συνθήκες. Παρατηρείται μια ξεκάθαρη αντίστροφη σχέση: οι ρύποι NO2 στην Αθήνα παρουσιάζουν κορύφωση κατά την χειμερινή περίοδο λόγω του συνδυασμού κλιματικών παραγόντων (αναστροφή) και της αυξημένης αστικής δραστηριότητας (θέρμανση, κυκλοφορία) ενώ παρουσιάζουν μείωση κατά την καλοκαιρινή περίοδο του συνδυασμού κλιματικών παραγόντων (έντονη ηλιοφάνεια και οι αέριδες) και της συμπεριφοράς των πολιτών (απουσία τους λόγω διακοπών).

7.4 Μέση μηνιαία διακύμανση O3 και Θερμοκρασίας (Διαχρονικά)

	month	avg_temp	avg_o3
▶	1	8.54	48.50
	2	8.69	57.71
	3	9.89	68.97
	4	14.49	74.84
	5	19.80	75.99
	6	24.30	79.32
	7	27.11	87.52
	8	27.18	84.78
	9	23.08	73.19
	10	17.90	60.20
	11	13.77	48.19
	12	10.85	44.40

4 - Αποτέλεσμα SQL ερωτήματος 6.4




Η ανάλυση της μέσης μηνιαίας διακύμανσης του Όζοντος (O3) αναδεικνύει μια άμεση θετική συσχέτιση μεταξύ της θερμοκρασίας και των επιπέδων του ρύπου. Σε αντίθεση με το NO2, το Όζον παρουσιάζει κορύφωση κατά την καλοκαιρινή περίοδο καθώς η έντονη ηλιακή ακτινοβολία και οι υψηλές θερμοκρασίες λειτουργούν ως καταλύτες για τις φωτοχημικές αντιδράσεις που το παράγουν. Αντίθετα, κατά τη χειμερινή περίοδο παρατηρείται σημαντική μείωση των τιμών λόγω της περιορισμένης ηλιοφάνειας.

7.5 Εντοπισμός ωρών αιχμής της ρύπανσης (NO2) κατά τη διάρκεια της ημέρας.

Hour_of_Day	Average_NO2	Traffic_Period
0	21.03	Εκτός Αιχμής
1	19.26	Εκτός Αιχμής
2	17.74	Εκτός Αιχμής
3	17.79	Εκτός Αιχμής
4	19.82	Εκτός Αιχμής
5	23.65	Πρωινή Αιχμή
6	26.01	Πρωινή Αιχμή
7	24.73	Πρωινή Αιχμή
8	22.19	Πρωινή Αιχμή
9	19.33	Εκτός Αιχμής
10	16.75	Εκτός Αιχμής
11	15.19	Εκτός Αιχμής
12	14.19	Εκτός Αιχμής
13	13.97	Εκτός Αιχμής
14	14.31	Εκτός Αιχμής
15	15.85	Εκτός Αιχμής
16	19.07	Εκτός Αιχμής
17	21.75	Εκτός Αιχμής
18	24.11	Εκτός Αιχμής
19	26.28	Απογευματινή Αιχμή
20	27.14	Απογευματινή Αιχμή
21	26.82	Απογευματινή Αιχμή
22	25.11	Απογευματινή Αιχμή
23	22.99	Εκτός Αιχμής

5 - Αποτέλεσμα SQL ερωτήματος 6.5




Η ωριαία ανάλυση των συγκεντρώσεων NO2 αναδεικνύει την άμεση επίδραση της αστικής κυκλοφορίας στην ποιότητα του αέρα. Παρατηρείται μια διπλή κορύφωση των ρύπων κατά τη διάρκεια του εικοσιτετράωρου, μια στην Πρωινή Αιχμή (05:00 - 08:00) συμπίπτοντας με την προσέλευση των πολιτών στην εργασία του και μια στην Απογευματινή/Βραδινή Αιχμή (19:00 - 22:00) γεγονός που αποδίδεται στον συνδυασμό της επιστροφής των οχημάτων και της έναρξης λειτουργίας των συστημάτων θέρμανσης κατά τους χειμερινούς μήνες

7.6 Μέση τιμή ρύπων κατά τις εργάσιμες ημέρες έναντι Σαββατοκύριακου.

day_type	avg_pm2_5	avg_pm10	avg_o3	avg_no2
Καθημερινή	14.80	22.21	66.77	21.24
Σαββατοκύριακο	15.76	23.19	68.50	19.09

6 - Αποτέλεσμα SQL ερωτήματος 6.6




Η ανάλυση των αποτελεσμάτων αναδεικνύει την πολυπαραγοντική φύση της ρύπανσης διότι το διοξείδιο του αζώτου (NO2) αποτελεί τον μοναδικό ρύπο που παρουσιάζει μείωση κατά το Σαββατοκύριακο, γεγονός που επιβεβαιώνει τη στενή του σύνδεση με την επαγγελματική οδική κυκλοφορία. Αντίθετα, τα αιωρούμενα σωματίδια (PM2.5, PM10) και το Όζον (O3) εμφανίζουν αυξημένες τιμές κατά τις ημέρες ανάπαυσης. Η αύξηση αυτή αποδίδεται στην εντατικότερη χρήση συστημάτων θέρμανσης και στις μεταβολές των φωτοχημικών ισορροπιών της ατμόσφαιρας λόγω της μειωμένης παρουσίας πρωτογενών ρύπων.

7.7 Ποσοστιαία κατανομή ποιότητας αέρα (NO2) βάσει ευρωπαϊκών προτύπων για το έτος 2022 (ανά εγγραφή)

	air_quality_level	total_measurements
►	Good	185963
	Fair	143966
	Moderate	135989
	Poor	29335
	Very poor	1445
	Extremely poor	36

7 - Αποτέλεσμα SQL ερωτήματος 6.7




Η ανάλυση των δεδομένων για το έτος 2022 αποκαλύπτει μια καλή εικόνα καθώς η συντριπτική πλειονότητα των ωριαίων μετρήσεων κατατάσσεται σε θετικές κατηγορίες. Συγκεκριμένα κυριαρχούν οι κατηγορίες “Good” και “Fair” (Κυριαρχία Ασφαλών Επιπέδων), μετά έχουμε τις μετρήσεις “Moderate” που είναι μεν σημαντικές αλλά όχι κυρίαρχες και τέλος οι κατηγορίες “Poor”, “Very Poor” και “Extremely Poor” αποτελούν ένα ελάχιστο ποσοστό του συνόλου που σημαίνει ότι ακραίες υπερβάσεις των ορίων NO2 είναι σπάνιο φαινόμενο για την Αθήνα.

7.8 Ποσοστιαία κατανομή ποιότητας αέρα (NO2) βάσει ευρωπαϊκών προτύπων για το έτος 2022 (ανά ημέρα)

	daily_air_quality	total_days
►	Good	1281
	Fair	3983
	Moderate	2854
	Poor	56

8 - Αποτέλεσμα SQL ερωτήματος 6.8




Ομαδοποιήσαμε το ερώτημα 6.7 (ωριαία) ανά ημέρα και καταλήξαμε ότι στην ημερήσια ανάλυση, οι κατηγορίες “Very Poor” και “Extremely Poor” εξαφανίζονται. Αυτό συμβαίνει διότι, ενώ μπορεί να υπάρξουν μεμονωμένες ώρες με πολύ υψηλή ρύπανση, ο μέσος όρος της ημέρας σπάνια διατηρείται σε τόσο υψηλά επίπεδα. Αυτό καθησυχάζει όσον αφορά τη συνεχή έκθεση, αλλά αναδεικνύει την ανάγκη για ωριαία παρακολούθηση για την προστασία ευπαθών ομάδων κατά τις ώρες αιχμής. Γενικά κυριαρχεί το “Fair” στην Αθήνα που σημαίνει ότι ο αέρας δεν είναι απόλυτα καθαρός αλλά παραμένει εντός ορίων που δεν απαιτούν έκτακτα μέτρα.

7.9 Ταξινόμηση μέσω τιμών NO2 ανά σταθμό και κατηγορία ποιότητας.

	station_name ▲	total_avg_no2	overall_air_quality_status	health_advice
▶	Ano Liosia (Peneri)	20.42	Fair	No risk for general population.
	ARISTOTELOUS	42.61	Moderate	Sensitive groups should reduce exertion
	ATH-ENVICARE-0	32.08	Moderate	Sensitive groups should reduce exertion
	ATH-ENVICARE-2	19.22	Fair	No risk for general population.
	ATH-ENVICARE-3	NULL	No Data	Insufficient measurements for this pe...
	Athens CAMS station 0	8.97	Good	Enjoy your outdoor activities.
	Athens CAMS station 1	7.31	Good	Enjoy your outdoor activities.
	Athens CAMS station 10	9.87	Good	Enjoy your outdoor activities.
	Athens CAMS station 11	7.03	Good	Enjoy your outdoor activities.
	Athens CAMS station 12	8.11	Good	Enjoy your outdoor activities.
	Athens CAMS station 13	7.29	Good	Enjoy your outdoor activities.
	Athens CAMS station 14	5.41	Good	Enjoy your outdoor activities.
	Athens CAMS station 15	19.70	Fair	No risk for general population.
	Athens CAMS station 16	20.43	Fair	No risk for general population.
	Athens CAMS station 17	19.23	Fair	No risk for general population.
	Athens CAMS station 18	12.04	Fair	No risk for general population.
	Athens CAMS station 19	7.39	Good	Enjoy your outdoor activities.
	Athens CAMS station 2	24.93	Fair	No risk for general population.
	Athens CAMS station 3	29.83	Moderate	Sensitive groups should reduce exertion
	Athens CAMS station 4	22.12	Fair	No risk for general population.
	Athens CAMS station 5	11.95	Fair	No risk for general population.
	Athens CAMS station 6	9.65	Good	Enjoy your outdoor activities.
	Athens CAMS station 7	17.46	Fair	No risk for general population.
	Athens CAMS station 8	20.65	Fair	No risk for general population.
	Athens CAMS station 9	15.25	Fair	No risk for general population.
	ATHENS_01	NULL	No Data	Insufficient measurements for this pe...

overall_air_quality_status	Καταμέτρηση από station_name	Έγινε καταμέτρηση όλων των σταθμών και χωρίστηκαν στις κατηγορίες ποιότητα αέρα.
Fair	26	
Good	11	
Moderate	14	
No Data	13	



8. Συμπεράσματα

Στην παρούσα εργασία ολοκληρώθηκε με επιτυχία ο σχεδιασμός και η υλοποίηση μιας Αποθήκης Δεδομένων για την περιβαλλοντική παρακολούθηση της Αθήνας για την περίοδο Μάιος 2020 με Μάιος 2023. Μέσα από την ανάλυση των 1,7+ εκατομμυρίων εγγραφών, προκύπτουν τα εξής κεντρικά συμπεράσματα:

8.1 Αξιολόγηση του Μοντέλου

- **Αποδοτικότητα Star Schema:** Η επιλογή του Σχήματος Αστέρα αποδείχθηκε ορθή, καθώς επέτρεψε την εκτέλεση σύνθετων ερωτημάτων σε εκατομμύρια γραμμές σε ελάχιστο χρόνο.
- **Σημασία του ETL:** Η προεπεξεργασία στο Power Query και ο καθαρισμός στη MySQL διασφάλισαν την ακεραιότητα των αποτελεσμάτων, μετατρέποντας ακατέργαστα δεδομένα σε αξιοποιήσιμη πληροφορία έτοιμη προς ανάλυση.

8.2 Περιβαλλοντικά Ευρήματα

- **Χωρική και Χρονική Ρύπανση:** Ο Κεντρικός Τομέας της Αθήνας παραμένει ο πιο επιβαρυνμένος, με τις ώρες αιχμής (πρωί και απόγευμα) να παρουσιάζουν τις μέγιστες τιμές NO₂ λόγω της κυκλοφορίας.
- **Εποχικότητα:** Επιβεβαιώθηκε η αντίστροφη σχέση NO₂ και Όζοντος, με το NO₂ να κορυφώνεται τον χειμώνα και το Όζον το καλοκαίρι λόγω φωτοχημικών αντιδράσεων.
- **Συνολική Ποιότητα:** Παρά τις ωριαίες αιχμές, η ημερήσια ανάλυση (Section 7.8) δείχνει ότι η Αθήνα το 2022 βρισκόταν κατά βάση στην κατηγορία "Fair", με τις ακραίες υπερβάσεις να αποτελούν σπάνια φαινόμενα.
- **Επίδραση της Κοινωνικοοικονομικής Δραστηριότητας:** Η σύγκριση καθημερινών και Σαββατοκύριακου ανέδειξε τον ρόλο της κυκλοφορίας των οχημάτων ως την κύρια πηγή NO₂, καθώς ο ρύπος παρουσιάζει αισθητή μείωση τις ημέρες ανάπαυσης. Αντίθετα, η αύξηση των αιωρούμενων σωματιδίων (PM) τα Σαββατοκύριακα υποδηλώνει την εντατικότερη χρήση συστημάτων θέρμανσης και την αλλαγή στις συνήθειες των πολιτών. Μας δείχνει ότι δεν μειώνονται όλοι οι ρύποι όταν σταματάει η δουλειά.

9. Βιβλιογραφία

Πρωτογενή Δεδομένα (Datasets):

Copernicus Atmosphere Monitoring Service (CAMS) / Zenodo. (2024). *Air Quality and Meteorological Data for Athens, Greece (2020-2023)*
<https://zenodo.org/records/11220965>

Kaggle Dataset. *Air Quality Monitoring in European Cities.* Συλλογή δεδομένων για την ατμοσφαιρική ρύπανση σε αστικά κέντρα
<https://www.kaggle.com/datasets/yekenot/air-quality-monitoring-in-european-cities>

European Environment Agency (EEA). *European Air Quality Index (AQI) - Maps and Charts.* Επίσημα όρια και κατηγοριοποίηση ρύπων
<https://www.eea.europa.eu/en/analysis/maps-and-charts/index?activeTab=8a280073-bf94-4717-b3e2-1374b57ca99d>

Εργαλεία Λογισμικού:

MySQL Workbench 8.0 CE - Σύστημα Διαχείρισης Σχεσιακών Βάσεων Δεδομένων.

Microsoft Power BI Desktop / Power Query Editor - Εργαλείο ETL και οπτικοποίησης δεδομένων.

DAX Studio - Εργαλείο εξαγωγής δεδομένων από το In-Memory μοντέλο του Power BI

Visual Paradigm - Εργαλείο σχεδίασης διαγραμμάτων ERD και Star Schema.

Σας ευχαριστώ πολύ

